

Classification de tumeurs mammaires par forêt aléatoire (Random Forest)

Optimisation et interprétation d'un modèle d'apprentissage automatique

Jeu de données : Breast Cancer Wisconsin (Diagnostic)

UCI Machine Learning Repository

Sommaire

1. Introduction et contexte	3
2. Méthodologie	3
3. Optimisation des hyperparamètres	4
4. Interprétation du modèle	4
4.1 Importance par permutation	4
4.2 Valeurs SHAP	5
4.3 Dépendance partielle	6
5. Lecture médicale des résultats	7
6. Interprétation à l'échelle du patient	8
6.1 Calibration des probabilités	8
6.2 Trois cas cliniques expliqués	8
6.3 Préconisations pour les médecins	10
7. Conclusion et limites	11

1. Introduction et contexte

Le cancer du sein est l'un des cancers les plus fréquents. Un diagnostic précoce et fiable améliore nettement le pronostic. L'apprentissage automatique offre un outil d'aide à la décision capable de distinguer une tumeur bénigne d'une tumeur maligne à partir de mesures quantitatives réalisées sur des images de cellules.

Ce projet met en œuvre un modèle de forêt aléatoire (Random Forest) pour cette tâche de classification binaire. L'objectif est double : obtenir de bonnes performances de prédiction, puis expliquer les décisions du modèle afin d'en dégager une interprétation compatible avec les connaissances médicales.

Le jeu de données

Les données proviennent du dépôt public UCI Machine Learning Repository (Breast Cancer Wisconsin – Diagnostic). Chaque observation correspond à une patiente et rassemble 30 variables numériques dérivées d'images de biopsies : rayon, périmètre, aire, texture, concavité, etc., calculées sous forme de moyenne, d'erreur type et de valeur extrême (« worst »).

Caractéristique	Valeur
Nombre de patientes	569
Nombre de variables	30
Tumeurs bénignes	357 (62,7 %)
Tumeurs malignes	212 (37,3 %)
Type de problème	Classification binaire

2. Méthodologie

La forêt aléatoire

La forêt aléatoire est une méthode d'ensemble qui agrège de nombreux arbres de décision. Chaque arbre est entraîné sur un échantillon tiré au hasard (bootstrap) des données et ne considère qu'un sous-ensemble aléatoire des variables à chaque division. La prédiction finale résulte d'un vote majoritaire. Cette double source d'aléa réduit le surapprentissage propre aux arbres individuels et rend le modèle robuste.

Trois atouts la rendent adaptée aux données médicales : **elle ne nécessite pas de normalisation des variables** (les arbres sont insensibles à l'échelle), elle gère naturellement les interactions entre variables, et elle fournit des mesures d'importance directement exploitables pour l'interprétation.

Protocole expérimental

- Séparation des données en 75 % pour l'entraînement et 25 % pour le test, avec stratification pour préserver la proportion bénin/malin.
- Entraînement d'un modèle de référence aux réglages par défaut.
- Optimisation des hyperparamètres par recherche aléatoire (RandomizedSearchCV, 40 combinaisons) évaluée par validation croisée à 5 plis sur le critère ROC AUC.
- Évaluation finale sur le jeu de test, jamais vu pendant l'entraînement.

3. Optimisation des hyperparamètres

La recherche aléatoire explore efficacement l'espace des configurations en tirant au hasard un nombre fixé de combinaisons, plutôt que de tester toutes les possibilités. Les meilleurs réglages retenus sont les suivants :

Hyperparamètre	Valeur retenue
n_estimators (nombre d'arbres)	800
max_depth (profondeur max)	10
max_features	log2
min_samples_leaf	4
min_samples_split	5
class_weight	balanced

Le meilleur score obtenu en validation croisée est un ROC AUC de 0,991, confirmant la stabilité du modèle. La comparaison sur le jeu de test met toutefois en évidence un résultat instructif :

Modèle	Exactitude	ROC AUC
Modèle de référence (défaut)	0,958	0,995
Modèle optimisé	0,951	0,994

Le modèle optimisé ne dépasse pas la version par défaut. Ce n'est pas un échec mais une leçon méthodologique : sur ce jeu de données propre, peu bruité et bien séparable, la forêt aléatoire par défaut est déjà proche de l'optimal. L'optimisation apporte surtout une meilleure garantie de robustesse (arbres plus contraints, poids de classe équilibrés) plutôt qu'un gain brut de performance. Il faut donc toujours comparer un modèle optimisé à une référence, sous peine de sur-interpréter un réglage sans effet réel.

4. Interprétation du modèle

Un bon score ne suffit pas en contexte médical : il faut comprendre sur quoi le modèle fonde ses décisions. Trois approches complémentaires sont mobilisées.

4.1 Importance par permutation

Cette méthode mesure la chute de performance (ROC AUC) lorsqu'on mélange aléatoirement les valeurs d'une variable sur le jeu de test. Plus la chute est forte, plus la variable est déterminante. Contrairement à l'importance native de la forêt, elle est évaluée sur des données non vues et donc moins biaisée.




Figure 1 — Importance par permutation (baisse moyenne du ROC AUC, barres d'erreur sur 30 répétitions).

Les variables liées aux points concaves (« concave points ») et à la concavité du contour cellulaire dominant largement, suivies de l'aire et de la texture. Ces mesures décrivent l'irrégularité de la forme des cellules.

4.2 Valeurs SHAP

Les valeurs SHAP décomposent chaque prédiction individuelle en contributions additives de chaque variable, sur des bases issues de la théorie des jeux. Elles offrent à la fois une vue globale et locale, exacte pour les modèles à base d'arbres.




Figure 2 — Diagramme SHAP en essai : chaque point est une patiente. La couleur code la valeur de la variable (rouge = élevée), la position horizontale son effet sur la prédiction.

La lecture du diagramme est riche : pour les variables « worst area », « worst perimeter » et les points concaves, des valeurs élevées (points rouges) poussent la prédiction vers la malignité. Autrement dit, plus

les cellules sont grandes et au contour irrégulier, plus le modèle penche vers une tumeur maligne — ce qui rejoint le raisonnement d'un pathologiste.




Figure 3 — Importance SHAP moyenne (magnitude moyenne de la contribution de chaque variable).

4.3 Dépendance partielle

Les courbes de dépendance partielle montrent comment la probabilité prédite évolue en fonction d'une variable, toutes choses égales par ailleurs. Elles précisent le sens et la forme de chaque effet.




Figure 4 — Dépendance partielle des quatre variables les plus influentes.

On observe des transitions marquées : au-delà d'un certain seuil d'aire ou de périmètre extrême, la probabilité prédite de bénignité chute brutalement. Ces seuils, appris automatiquement, pourraient être rapprochés de repères cliniques.

5. Lecture médicale des résultats

La convergence des trois méthodes est rassurante : elles désignent toutes les mêmes familles de variables. Le modèle s'appuie sur des caractéristiques morphologiques bien connues des pathologistes.

- **Points concaves et concavité** : un contour cellulaire très échancré traduit une prolifération anarchique typique des cellules cancéreuses.
- **Taille (aire, périmètre, rayon)** : les cellules malignes tendent à être plus grandes et irrégulières.
- **Valeurs « worst »** : ce sont les cellules les plus atypiques d'un prélèvement qui sont les plus informatives, ce qui est cohérent avec la pratique clinique.

Cette cohérence entre le modèle et le savoir médical renforce la confiance qu'on peut lui accorder comme outil d'aide à la décision — sans jamais se substituer au diagnostic d'un professionnel.

6. Interprétation à l'échelle du patient

Les analyses précédentes décrivent le comportement moyen du modèle sur toute la population : elles servent à le valider. En situation clinique réelle, l'enjeu est différent : il faut interpréter la prédiction d'UNE patiente donnée. On passe donc d'une lecture globale à une lecture locale, patiente par patiente, assortie d'une probabilité fiable et d'une explication rattachée à des variables cliniques.

6.1 Calibration : rendre les probabilités dignes de confiance

Une forêt aléatoire produit des scores qui ne correspondent pas toujours à de vraies probabilités : un score de 0,8 ne signifie pas nécessairement « 80 % de chances ». La calibration corrige ce décalage. La courbe de fiabilité ci-dessous compare la probabilité prédite (axe horizontal) à la fréquence réellement observée (axe vertical) : plus les points suivent la diagonale, mieux le modèle est calibré.




Figure 5 — Courbe de fiabilité avant et après calibration isotonique. Le score de Brier mesure l'écart à la calibration parfaite (plus bas = mieux).

Interprétation précise : les deux courbes suivent déjà la diagonale de près et les scores de Brier sont quasi identiques (0,033 brut contre 0,033 calibré). Le modèle est donc **déjà bien calibré** sur ce jeu de données propre : une probabilité affichée de 80 % correspond réellement à environ 80 % de tumeurs bénignes. Ce résultat est rassurant mais spécifique à des données idéales. Sur des données hospitalières réelles, plus bruitées et hétérogènes, cette étape de calibration est indispensable et corrige souvent des écarts importants — c'est pourquoi elle doit figurer dans tout protocole, même quand son gain est faible ici.

6.2 Trois cas cliniques expliqués

Pour chaque patiente, un graphique SHAP en cascade (« waterfall ») décompose la prédiction. On part de la prédiction moyenne du modèle ($E[f(x)] = 0,5$), puis chaque variable ajoute une poussée : vers la droite (rouge) elle augmente la probabilité de bénignité, vers la gauche (bleu) elle l'abaisse (vers la malignité). La somme des poussées donne la prédiction finale $f(x)$ pour cette patiente. Trois profils typiques sont présentés.

Cas n°1 — Tumeur bénigne franche (patiente #9)




Figure 6 — Décomposition SHAP d'un cas bénin franc (probabilité calibrée de bénignité : 100 %).

Interprétation précise : toutes les variables majeures poussent dans le même sens, vers la bénignité. L'aire extrême des cellules est faible (worst area = 497, contribution +0,063), de même que le périmètre (80,8, +0,062) et les points concaves (+0,055). Des cellules petites et au contour régulier sont typiques d'une lésion bénigne. Le faisceau de preuves est cohérent et unanime : le modèle conclut à 100 % de bénignité, sans ambiguïté. Cliniquement, ce cas ne nécessite pas d'attention particulière du système d'aide à la décision.

Cas n°2 — Tumeur maligne franche (patiente #1)




Figure 7 — Décomposition SHAP d'un cas malin franc (probabilité calibrée de bénignité : 0 %).

Interprétation précise : c'est le miroir exact du cas précédent. Toutes les variables poussent vers la malignité. L'aire extrême est très élevée (worst area = 1349, soit près du triple du cas bénin, contribution $-0,071$), le périmètre atteint 138 ($-0,069$) et les points concaves 0,20 ($-0,060$). Des cellules volumineuses au contour très échancré signent une prolifération anarchique. Là encore, les preuves convergent : le modèle conclut à 0 % de bénignité. La forte cohérence des contributions renforce la confiance dans la prédiction.

Cas n°3 — Cas incertain, près du seuil (patiente #88)




Figure 8 — Décomposition SHAP d'un cas incertain (probabilité calibrée de bénignité : 52 %).

Interprétation précise : ce cas est le plus instructif. Contrairement aux deux précédents, les variables se **contredisent**. Certaines poussent vers la malignité (mean concave points = 0,085, contribution $-0,055$; worst concave points $-0,034$; mean concavity $-0,028$), d'autres vers la bénignité (worst texture = 18,3, $+0,049$; worst concavity $+0,049$). Ces poussées opposées s'annulent presque : la prédiction finale reste collée au seuil (score brut 0,46, probabilité calibrée 52 % de bénignité). Fait notable, la calibration a légèrement rehaussé le score au-dessus de 50 %, faisant basculer la décision vers « bénin » — ce qui illustre à quel point, sur un cas limite, le résultat est fragile.

Cette patiente est en réalité bénigne, et le modèle a raison — mais de justesse. En pratique hospitalière, c'est exactement le type de cas que le système doit signaler comme « incertain, à confirmer par le clinicien » plutôt que de trancher silencieusement. Un examen complémentaire ou un second avis y est justifié.

6.3 Préconisations pour l'information donnée aux médecins

De ces trois cas découlent des principes concrets pour concevoir l'affichage d'un outil d'aide à la décision destiné aux cliniciens. L'objectif est d'informer sans induire en erreur ni provoquer de biais d'automatisation (la tendance à suivre aveuglément la machine).

- **Afficher une probabilité calibrée, jamais une simple étiquette.** « 52 % de probabilité de bénignité » informe le médecin bien mieux que « bénin », qui masque l'incertitude.

- **Signaler explicitement les cas limites.** Toute prédiction proche du seuil (par exemple entre 40 % et 60 %) doit être accompagnée d'un avertissement « cas incertain — jugement clinique requis », comme pour la patiente #88.
- **Montrer les 3 à 5 facteurs déterminants, en langage clinique.** Indiquer les variables qui ont le plus pesé et leur sens (« taille cellulaire élevée : oriente vers malignité »), pour que le médecin puisse recouper avec son propre examen.
- **Alerter sur les cas atypiques.** Si les mesures d'une patiente sortent de la plage des données d'apprentissage, le modèle extrapole et son explication devient peu fiable : il faut le signaler.
- **Rappeler le statut d'aide à la décision.** L'affichage doit énoncer que la décision finale revient au médecin, conformément à l'exigence de supervision humaine du cadre réglementaire (MDR et AI Act).
- **Assurer la traçabilité.** Version du modèle, date, et possibilité de signaler une erreur : indispensable pour le suivi après mise sur le marché et l'amélioration continue.

7. Conclusion et limites

La forêt aléatoire atteint d'excellentes performances (ROC AUC $\approx 0,99$, exactitude ≈ 96 %) sur la classification bénin/malin. L'analyse d'interprétabilité montre qu'elle fonde ses décisions sur des variables morphologiques médicalement pertinentes, ce qui la rend crédible au-delà du seul score.

Plusieurs limites méritent d'être soulignées : le jeu de données est de taille modeste et issu d'un seul centre, ce qui interroge la généralisation ; l'optimisation n'a pas amélioré la performance, signe que d'autres leviers (ingénierie de variables, autres modèles) seraient à explorer ; enfin, un déploiement clinique exigerait une validation externe rigoureuse et un cadre réglementaire adapté.

Pistes d'amélioration : valider sur une cohorte externe, comparer à d'autres algorithmes (gradient boosting, régression logistique régularisée), et étudier les cas mal classés pour comprendre les erreurs du modèle.